Исследовательский проект по дисциплине "Анализ временных рядов"

Дорохов М. А., Степанов А. В.

Москва, 2026 г.

1 Введение

В этом исследовательском проекте мы изучали влияние нормализации данных на качество моделей прогнозирования разных видов: статистические бэйзлайны (`Naive`, `SeasonalNaive`, `AutoETS` и `AutoTheta`), модель машинного обучения (`Catboost`), нейросетевая модель (`PatchTST`). Для локальных статистических методов этот вопрос часто считается второстепенным, тогда как для глобальных моделей, особенно нейросетевых, различие масштабов между рядами может напрямую влиять на устойчивость обучения.

В качестве эмпирической базы выбрана подвыборка из датасета M4 Monthly, который является стандартным ориентиром для сравнений в задачах прогнозирования.

Постановка задачи

Мы провели исследование для проверки следующей гипотезы:

(2) Нормализация по рядам особенно важна для глобальных нейронных моделей, но влияет неоднозначно на модели из разных классов.

Для этого выделены следующие задачи:

1. Зафиксировать бейзлайны и две глобальные модели для основных экспериментов (например, CatBoost и PatchTST).
2. Сравнить качество моделей (бейзлайнов тоже) с применением StandardScaling и без его применения.
3. Сравнить качество моделей с применением не менее двух других вариантов скейлинга (QuantileScaling, RobustScaling).
4. Отдельно проанализировать, одинаково ли влияет нормализация на модели разных классов.

Фактически эксперимент отвечает на четыре исследовательских вопроса. Во-первых, какое масштабирование дает лучшую среднюю точность для базовых моделей. Во-вторых, отличается ли реакция `CatBoost` от статистических моделей. В-третьих, насколько сильно `PatchTST` зависит от нормализации. В-четвертых, подтверждаются ли средние значения распределениями ошибок по отдельным рядам.

Распределение ролей

Дорохов М. А. отвечал за разработку сценария запуска эксперимента, загрузку и подготовку данных, реализацию нормализации, вычисление метрик качества и общую логику оценки моделей. В его задачи также входили проверка корректности train/test-разбиения, сохранение результатов в таблицы.

Степанов А. В. отвечал за реализацию бэйзлайнов, древесных и нейросетевых моделей прогнозирования, подбор рабочих параметров для `CatBoost` и `PatchTST`, подготовку аналитического ноутбука с визуализациями. Кроме того, он выполнял сравнительный анализ влияния различных способов масштабирования на качество прогнозирования.

Выбор темы исследования и интерпретация результатов осуществлялись совместно.

Описание датасета

В полном файле M4 Monthly содержится 48 000 месячных временных рядов переменной длины. Для эксперимента была взята воспроизводимая выборка из 100 рядов при `seed = 42`. Каждый ряд разделялся на обучающую и тестовую части по схеме `train = все наблюдения, кроме последних 18` и `test = последние 18`. Таким образом, горизонт прогноза во всех сценариях был одинаковым и равнялся $h = 18$ шагам.

Длины train-частей в выбранной подвыборке оказались неоднородными: минимальная длина равна 44, медианная — 167, средняя — 202.65, максимальная — 996 наблюдений. Это важно для интерпретации результатов, поскольку глобальные модели обучались на общей панели рядов с существенно различающимися шкалами и историей наблюдений. Поскольку в данных отсутствуют абсолютные временные метки, для глобальных моделей использовалась синтетическая месячная временная ось, одинаковая для всех рядов.

2 Исследование

Методология эксперимента

Для каждого ряда отдельный скейлер обучался только на train-части. После этого масштабированная train-часть использовалась при обучении модели, а прогнозы обязательно переводились обратно в исходную шкалу перед вычислением метрик.

Сравнивались четыре стратегии.

1. `none` оставляет ряд без изменений.
2. `standard` центрирует train по среднему и делит на стандартное отклонение:
$$x_t^{(std)} = \frac{x_t - \mu_{train}}{\sigma_{train}}.$$
3. `robust` использует медиану и межквартильный размах, что делает преобразование менее чувствительным к выбросам:
$$x_t^{(robust)} = \frac{x_t - \mathrm{Med}_{train}}{\mathrm{IQR}_{train}}.$$
4. Стратегия `quantile` строит эмпирическое квантильное преобразование, переводящее train-часть в пространство, приближенное к нормальному распределению.

Качество прогнозов оценивалось по четырем метрикам: `MAE`, `RMSE`, `sMAPE` и `MASE`. Выбор именно этого набора обусловлен тем, что он позволяет сравнивать модели с разных сторон и не ограничиваться одной характеристикой ошибки. Метрика `MAE` измеряет среднюю абсолютную ошибку в исходной шкале и легко интерпретируется как среднее отклонение прогноза от фактических значений. Метрика `RMSE` сильнее штрафует большие ошибки за счет квадратичного усреднения, поэтому она полезна, если важно учитывать редкие, но крупные промахи модели. Метрика `sMAPE` является масштабно-инвариантной и особенно удобна при сравнении качества на разных рядах, поскольку значения M4 могут существенно различаться по уровню и вариации. Наконец, `MASE` позволяет интерпретировать качество модели относительно сезонного наивного прогноза, то есть показывает, насколько модель

лучше или хуже простого, но сильного бейзлайна. Для MASE в знаменателе использовалась ошибка сезонного наивного прогноза с сезонностью $m = 12$, что естественно для месячных рядов; если вычисление сезонного масштаба было невозможно, применялся безопасный переход к лагу 1. Таким образом, выбранный набор метрик объединяет интерпретируемость в исходной шкале, чувствительность к крупным ошибкам, сопоставимость между рядами разного масштаба и сравнение с естественным сезонным бейзлайном. Анализ проводился на двух уровнях: по средним метрикам для каждой комбинации `model × scaling` и по распределениям ошибок на уровне отдельных рядов.

Описание моделей

Статистические базовые модели (бейзлайны). В базовый набор вошли Naive, SeasonalNaive, AutoETS и AutoTheta. Первые две модели выступают нижней границей сложности и позволяют проверить, влияет ли масштабирование вообще на методы, где прогноз практически не зависит от глобальной оптимизации. AutoETS автоматически подбирает экспоненциальную модель сглаживания, а AutoTheta используется в аддитивной версии, чтобы корректно работать после центрирующих преобразований.

ML-модель CatBoost. CatBoost реализован как глобальная рекурсивная одношаговая модель на объединенных лаговых признаках. Для каждого обучающего наблюдения формировались признаки lag_1–lag_24, позиция в сезонном цикле, индекс времени и статистики хвоста ряда на окнах 3, 6 и 12. Идентификатор ряда передавался как категориальный признак. В эксперименте использовались 300 итераций бустинга, глубина 6 и скорость обучения $\eta = 0.05$.

Нейросетевая модель PatchTST. PatchTST представляет собой трансформер для временных рядов, который работает с патчами последовательности и обучается глобально на панели рядов. В нашем эксперименте использовалась облегченная конфигурация: `input_size = 24`, `max_steps = 50`, `batch_size = 32`, `windows_batch_size = 512`, `learning_rate = 1e-3`. Внутреннее масштабирование модели было явно отключено через `scaler_type = identity` и `revin = false`, чтобы эффект внешних скейлеров можно было анализировать отдельно.

3 Результаты

Таблица 1 суммирует ключевые агрегированные результаты по двум метрикам, наиболее удобным для сопоставления с визуализациями из ноутбука: sMAPE и MASE. Рисунок 1 показывает средние значения sMAPE по всем моделям, а рисунок 2 дополняет их распределениями ошибок по отдельным рядам.

Если смотреть на базовые модели в среднем как на класс, то наиболее устойчивым вариантом оказывается standard. Он имеет лучший средний ранг по четырем метрикам (MAE, RMSE, sMAPE, MASE) и занимает первое место по MAE и RMSE. Однако эффект остается умеренным и неоднородным. Для AutoETS лучшей конфигурацией по sMAPE стала standard (10.79), тогда как для AutoTheta заметно лучше сработал quantile (11.93 против 13.82 без масштабирования). При этом Naive и SeasonalNaive вообще не реагируют на масштабирование, что ожидаемо для инвариантных относительно линейного преобразования базовых правил прогноза.

Реакция CatBoost оказывается более системной, чем у статистических моделей. Для него standard дает лучшие средние результаты сразу по всем метрикам: sMAPE снижается с 12.76 до 11.89, а MASE с 1.113 до 0.940. Относительное улучшение по sMAPE состав-

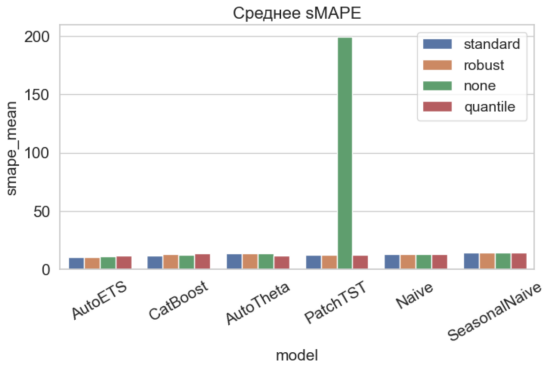

Рис. 1: Среднее значение `sMAPE` для всех комбинаций `model x scaling`.

ляет около 6.8%, а по `MASE` около 15.5% по сравнению с `none`. При этом доминирование `standard` не является абсолютным на уровне каждого отдельного ряда: примерно в 57% серий стандартизация лучше `none` по `sMAPE` и `MASE`. Значит, выигрыш возникает не только за счет нескольких выбросов, но и не является полностью универсальным.

Самая сильная зависимость от нормализации наблюдается у `PatchTST`. Без масштабирования модель фактически деградирует: среднее `sMAPE` равно 199.59, а среднее `MASE` 19.507. После любой нормализации ошибки падают до диапазона `sMAPE` 12.43–12.80 и `MASE` 1.016–1.066. Лучший вариант по `sMAPE` дает `robust`, а по `MASE` `standard`. Если сравнить лучший нормализованный вариант с `none`, улучшение составляет около 16 раз по `sMAPE` и 19 раз по `MASE`. Это означает, что для глобальной нейросетевой модели внешний контроль масштаба входов не просто полезен, а практически обязателен.

Распределения по отдельным рядам в целом подтверждают картину, которую дают средние значения, но позволяют точнее понять природу эффекта. Для `PatchTST` подтверждение максимально сильное: без масштабирования медиана `sMAPE` равна 199.92, все 100 рядов имеют `sMAPE` выше 100, а в 71 случае `MASE` превышает 5. После любой нормализации таких рядов почти не остается. Для `CatBoost` стандартизация сдвигает вниз не только среднее, но и медиану: медианный `sMAPE` уменьшается с 9.66 до 8.34, а медианный `MASE` с 0.86 до 0.75. Для `AutoTheta` ситуация тоньше: выигрыш `quantile` по среднему `sMAPE` достигается в первую очередь за счет уменьшения тяжелого хвоста ошибок, так как медиана у него не лучше, чем у вариантов без нормализации.

Выводы

По итогам эксперимента можно сформулировать четыре основных вывода.

1. Для базовых моделей наилучший общий компромисс дает `standard`-масштабирование. Оно лидирует по среднему рангу среди всех четырех метрик, хотя не является лучшим для каждой модели и каждой метрики по отдельности.

2. `CatBoost` реагирует на масштабирование более системно, чем статистические модели. Для него `standard` улучшает и типичные, и средние ошибки, тогда как у статистических методов эффект либо слабый, либо зависит от конкретной модели.

3. `PatchTST` зависит от нормализации на порядок сильнее остальных. Без масштабирования модель практически неработоспособна, тогда как после нормализации становится сопоставимой с `CatBoost` и сильными статистическими базовыми моделями.

4. Распределения ошибок по отдельным рядам в целом подтверждают выводы, сделанные по средним значениям. Наиболее наглядно это видно у `PatchTST` и `CatBoost`. Исключение связано с `AutoTheta`: преимущество `quantile` по среднему `sMAPE` объясняется в основном

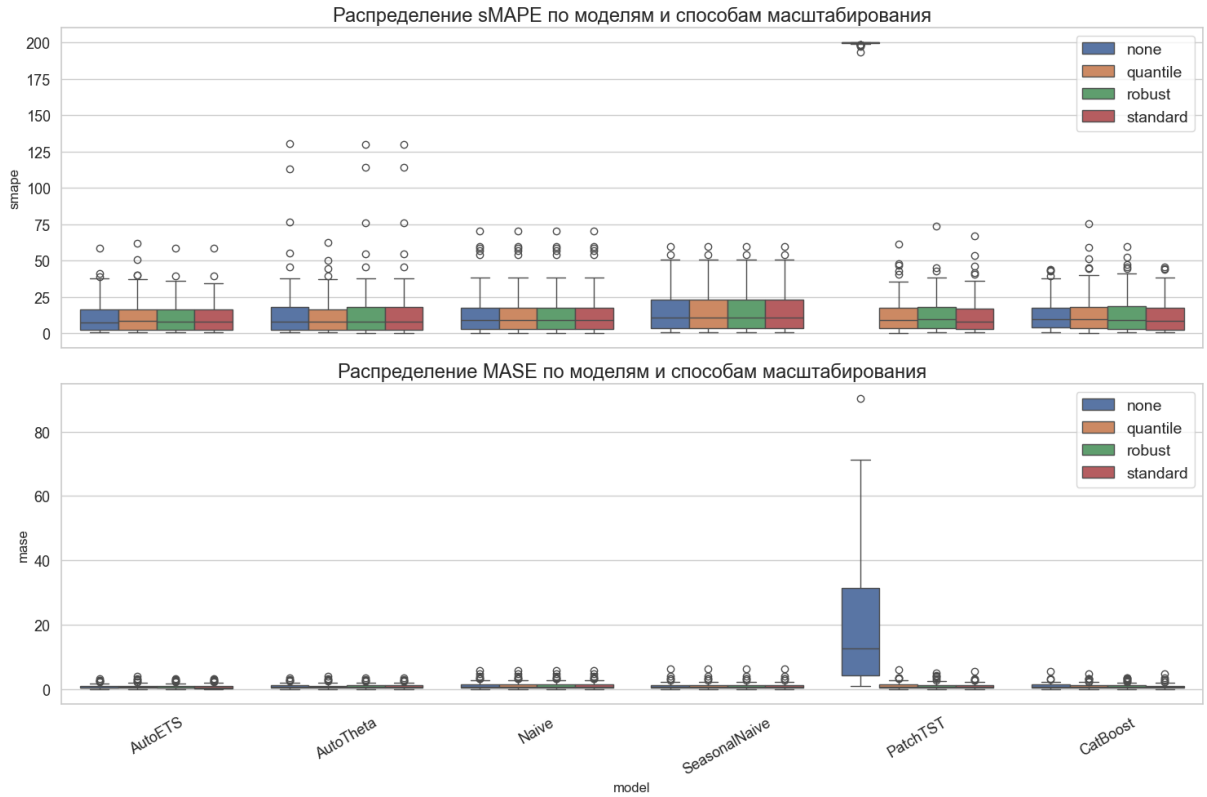

Рис. 2: Распределения ошибок по отдельным временным рядам. Для читаемости на boxplot скрыты крайние выбросы, но они учитывались при расчете средних значений и при формулировке выводов.

сокращением тяжелого хвоста ошибок, а не улучшением типичного случая.

Приводя общий вывод, гипотезу можно считать подтвержденной. Мы установили, что без применения нормализации трансформерная модель `PatchTST` становится неадекватной, когда бэйзлайны в свою очередь не получают столь однозначного эффекта.

Модель	sMAPE				MASE			
	none	standard	robust	quantile	none	standard	robust	quantile
AutoETS	11.09	**10.79**	10.84	12.14	**0.845**	0.852	0.852	0.922
AutoTheta	13.82	13.94	13.97	**11.93**	**0.911**	0.916	0.916	0.919
Naive	13.31	13.31	13.31	13.31	1.153	1.153	1.153	1.153
SeasonalNaive	14.47	14.47	14.47	14.47	1.123	1.123	1.123	1.123
CatBoost	12.76	**11.89**	13.11	13.54	1.113	**0.940**	1.000	1.067
PatchTST	199.59	12.44	**12.43**	12.80	19.507	**1.016**	1.044	1.066

Таблица 1: Средние значения sMAPE и MASE для всех моделей и вариантов масштабирования. Результаты получены на выборке из 100 рядов при горизонте прогноза 18.